

RAG 解析流水线核心功能测试文档

本文档专门用于验证 PDFLoader 的双栏布局提取、表格物理顺序混排以及低文本扫描件判定等核心工业级功能。

1. 基础单栏文本测试

在 RAG（检索增强生成）系统的离线知识库摄入阶段，解析模块的健壮性直接决定了下游检索的精准度。如果解析出的文本格式混乱、顺序颠倒，即使使用最先进的向量模型，也无法召回正确的上下文。

2. 物理双栏布局测试 (Dual-Column Layout Test)

[左栏：向量检索与 Embedding 维度]

向量数据库在 RAG 架构中扮演着核心角色。我们将高维稠密向量存储在 PostgreSQL (pgvector) 或专门的向量数据库中。通过计算余弦相似度 (Cosine Similarity)，系统能够秒级找出与用户查询 (Query) 最相关的文本切块 (Chunks)。为了确保检索的绝对精度，子块 (Child Chunks) 的 Token 大小通常限制在 150 到 200 之间。这种精细的分块策略可以极大减少检索噪声。

[右栏：LLM 上下文窗口与生成限制]

当检索模块召回相关切块后，大语言模型 (LLM) 需要这些切块来生成最终答案。然而，LLM 具有硬性的上下文窗口限制，且过长的无用信息会导致大模型在生成时出现“迷失在中间” (Lost in the Middle) 现象。因此，我们采用父子块双路索引。当检索命中精细的子块时，系统自动关联并加载其背后的父块 (约 800 Tokens) 送入模型，以平衡检索精度与生成上下文的完整度。

3. 表格物理顺序提取测试 (Table Interleaving Test)

在下面这个测试段落中，我们故意将一个复杂的系统性能对比表格夹在两段正文之间。**优秀的解析器应该能在输出中保持“正文 1 → Markdown 表格 → 正文 2”的物理阅读顺序**，而不是将表格无脑堆砌在页面最下方。

[正文 1：系统评测准备]

我们对三个主流的 RAG 向量存储方案进行了基准测试 (Benchmark)。测试环境为单台 16 核 32G 内存的服务器，使用 nomic-embed-text 向量模型，对 10 万条标准中文知识库文档进行并发写入和检索测试，以下是各系统的吞吐量与检索时延数据：

存储引擎 (Engine)	写入吞吐量 (QPS)	平均检索时延 (Latency)	混合检索支持 (Hybrid)	内存占用 (Memory)
PostgreSQL + pgvector	1,200	8.5 ms	支持 (全文本 + 向量)	较小
Milvus (Standalone)	3,500	4.2 ms	仅限向量	中等
Elasticsearch	1,800	12.0 ms	支持 (极其强大)	较大

[正文 2：评测结果分析]

通过上述表格数据可以看出，虽然 Milvus 在纯向量检索的写入吞吐量和时延上表现抢眼，但 PostgreSQL 凭借极其优秀的混合检索支持 (Hybrid Search) 以及极低的额外运维成本，成为了中小规模企业级 RAG 落地时的首选方案。

4. 低文本与图像占比测试 (OCR Fallback Test)

本地图片测试：



网络图片：



提示：由于此页面文本字符数极少（低于阈值），且图像面积占比较大，它应该能够成功激活解析器的 OCR 降级识别流程。